

UTS Supervised Learning

Rafly Priyantama Ramadhan Bagaskara

2025-10-19

Studi Kasus: Audit dan Optimalisasi Model Gaji di PT. Digital Cemerlang

Latar Belakang

Tim data internal PT. Digital Cemerlang telah mencoba membangun sebuah model untuk memprediksi gaji karyawan (Gaji_Bulanan) berdasarkan 20 faktor lainnya. Namun, hasil model awal mereka sangat meragukan. Meskipun model tersebut memiliki kemampuan prediksi yang tampak tinggi, koefisien (pengaruh) dari beberapa variabel kunci tidak stabil dan seringkali bertentangan dengan logika bisnis. Terdapat kecurigaan kuat bahwa ada masalah mendasar dalam data atau metode yang digunakan.

Anda bertindak sebagai konsultan independen yang ditugaskan untuk melakukan audit menyeluruh. Tugas Anda adalah mengidentifikasi sumber masalah, membangun model alternatif yang lebih valid dan andal, serta memberikan rekomendasi akhir kepada manajemen.

Tujuan

Mendiagnosis kelemahan model linier standar pada dataset yang diberikan, menerapkan pendekatan pemodelan yang sesuai untuk memperbaiki masalah tersebut, dan memilih model final terbaik yang seimbang antara akurasi prediksi dan validitas inferensial.

Informasi Data

Berikut contoh dari 10 data :

```
## # A tibble: 10 x 21
##   Tingkat_Pendidikan Pengalaman_Kerja Pelatihan_Sertifikasi Jam_Kerja_Mingguan
##   <dbl> <dbl> <dbl> <dbl>
## 1 9.41 4.03 5 51.1
## 2 17.0 1.28 4 40.2
## 3 12.0 8.38 1 48.8
## 4 10.7 7.85 3 51.0
## 5 8.51 8.27 2 34.6
## 6 8.51 3.41 7 36.8
## 7 8.18 4.07 5 37.2
## 8 14.0 3.99 3 44.6
## 9 10.8 11.7 4 50.0
## 10 11.7 6.76 5 31.0
## # i 17 more variables: Jumlah_Projek_Selesai <dbl>,
```

```
## # Skor_Evaluasi_Kinerja <dbl>, Jumlah_Bawahan <dbl>,
## # Lama_Di_Perusahaan <dbl>, Tingkat_Tanggung_Jawab <dbl>,
## # Frekuensi_Lembur <dbl>, Jumlah_Klien_Ditangani <dbl>,
## # Skor_Kepemimpinan <dbl>, Tingkat_Stress_Kerja <dbl>,
## # Produktivitas_Harian <dbl>, Kemampuan_Komunikasi <dbl>,
## # Inovasi_Dihasilkan <dbl>, Ketepatan_Deadline <dbl>, ...
```

Dataset terdiri dari 5000 observasi, 1 variabel target (Gaji_Bulanan), dan 20 variabel fitur.

```
##          Nama_Variabel
## 1      Tingkat_Pendidikan
## 2      Pengalaman_Kerja
## 3      Pelatihan_Sertifikasi
## 4      Jam_Kerja_Mingguan
## 5      Jumlah_Proyek_Selesai
## 6      Skor_Evaluasi_Kinerja
## 7      Jumlah_Bawahan
## 8      Lama_Di_Perusahaan
## 9      Tingkat_Tanggung_Jawab
## 10     Frekuensi_Lembur
## 11     Jumlah_Klien_Ditangani
## 12     Skor_Kepemimpinan
## 13     Tingkat_Stress_Kerja
## 14     Produktivitas_Harian
## 15     Kemampuan_Komunikasi
## 16     Inovasi_Dihasilkan
## 17     Ketepatan_Deadline
## 18     Kolaborasi_Tim
## 19     Adaptabilitas_Teknologi
## 20     Kontribusi_Pendapatan
## 21     Gaji_Bulanan
```

```
##
## 1          Skor kuantitatif yang merepresentasikan level pendidikan formal tertinggi yang dicapai
## 2          Total masa kerja relevan yang dimiliki karyawan sebelum dan selama di perusahaan, dalam sa
## 3          Jumlah total pelatihan profesional atau sertifikasi keahlian yang dimiliki
## 4          Rata-rata jumlah jam kerja karyawan dalam s
## 5          Akumulasi jumlah proyek yang telah berhasil diselesaikan ole
## 6          Nilai hasil tinjauan kinerja tahunan dari atasan, dengan si
100.
## 7          Jumlah karyawan yang melapor secara langsung kepada karyawan tersebut (bawahan
## 8          Masa kerja karyawan di PT. Digital Cemerlang, dalam sa
## 9          Skor kuantitatif yang mengindikasikan level dan kompleksitas tanggung jawab
## 10         Rata-rata frekuensi kerja lembur yang dilakukan karyawan dalam s
## 11         Jumlah klien aktif yang menjadi tanggung jawab
## 12         Penilaian kemampuan kepemimpinan berdasarkan observasi atau survei, dengan si
100.
## 13         Skor persepsi tingkat stres terkait pekerjaan yang dilaporkan sendiri oleh
## 14         Skor numerik yang mengukur rata-rata output atau hasil kerja harian
## 15         Penilaian efektivitas komunikasi interpersonal dan profesional, dengan si
100.
## 16         Jumlah kontribusi ide, proses, atau produk inovatif yang telah diimple
## 17         Persentase tugas dan proyek yang diselesaikan tepat waktu atau lebih
## 18         Penilaian kemampuan bekerja sama dan berkontribusi dalam tim, dengan si
100.
```

```

## 19                               Skor yang mengukur kecepatan dan kemahiran karyawan dalam mengadopsi tekn
## 20 Estimasi kontribusi finansial yang dihasilkan oleh karyawan untuk perusahaan, dalam jutaan Rupiah
## 21                               Gaji yang diterima karyawan per bulan, dalam satuan juta
##      Variabel
## 1      X1
## 2      X2
## 3      X3
## 4      X4
## 5      X5
## 6      X6
## 7      X7
## 8      X8
## 9      X9
## 10     X10
## 11     X11
## 12     X12
## 13     X13
## 14     X14
## 15     X15
## 16     X16
## 17     X17
## 18     X18
## 19     X19
## 20     X20
## 21      Y

```

Pertanyaan dan Instruksi Pengerjaan

Lakukan analisis secara sistematis sesuai alur di bawah ini. Setiap klaim atau kesimpulan harus didukung oleh bukti visual (plot) atau kuantitatif (hasil uji/metrik) dari analisis Anda.

1. Konstruksi dan Diagnosis Model Awal

- Bangun sebuah model linier dasar (Model A) yang menggunakan semua variabel fitur untuk memprediksi Gaji_Bulanan. Sajikan ringkasan statistik dari model ini.

```

library(tidyverse)
library(caret)
library(broom)
library(ggpubr)

# Split data
set.seed(42)
train_index <- createDataPartition(df$Gaji_Bulanan, p = 0.7, list = FALSE)
train_data <- df[train_index, ]
test_data <- df[-train_index, ]

# Model A - OLS dengan semua variabel
model_A <- lm(Gaji_Bulanan ~ ., data = train_data)
summary_model_A <- summary(model_A)

```

```
## _____RINGKASAN STATISTIK MODEL A_____
```

```
##
## Call:
## lm(formula = Gaji_Bulanan ~ ., data = train_data)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -4.1439 -0.9256 -0.0531  0.8342  5.6927
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)      7.799847   0.467601  16.681 < 2e-16 ***
## Tingkat_Pendidikan 2.498466   0.008395 297.627 < 2e-16 ***
## Pengalaman_Kerja   1.781991   0.020149  88.441 < 2e-16 ***
## Pelatihan_Sertifikasi 0.783857   0.013678  57.307 < 2e-16 ***
## Jam_Kerja_Mingguan 0.300015   0.002945 101.881 < 2e-16 ***
## Jumlah_Proyek_Selesai 0.109645   0.005780  18.969 < 2e-16 ***
## Skor_Evaluasi_Kinerja 0.160189   0.005465  29.309 < 2e-16 ***
## Jumlah_Bawahan     0.478956   0.025723  18.620 < 2e-16 ***
## Lama_Di_Perusahaan 0.417171   0.015159  27.519 < 2e-16 ***
## Tingkat_Tanggung_Jawab 1.231239   0.024670  49.908 < 2e-16 ***
## Frekuensi_Lembur    0.211760   0.012611  16.792 < 2e-16 ***
## Jumlah_Klien_Ditangani 0.059217   0.008136   7.278 4.17e-13 ***
## Skor_Kepemimpinan   0.095166   0.002406  39.558 < 2e-16 ***
## Tingkat_Stress_Kerja -0.306550   0.023812 -12.874 < 2e-16 ***
## Produktivitas_Harian 0.241663   0.006531  37.003 < 2e-16 ***
## Kemampuan_Komunikasi 0.080243   0.002851  28.148 < 2e-16 ***
## Inovasi_Dihasilkan   0.403511   0.011269  35.806 < 2e-16 ***
## Ketepatan_Deadline   0.060177   0.002923  20.585 < 2e-16 ***
## Kolaborasi_Tim       0.040201   0.001957  20.544 < 2e-16 ***
## Adaptabilitas_Teknologi 0.063547   0.003288  19.326 < 2e-16 ***
## Kontribusi_Pendapatan 0.019244   0.001211  15.894 < 2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 1.368 on 3479 degrees of freedom
## Multiple R-squared:  0.993, Adjusted R-squared:  0.993
## F-statistic: 2.468e+04 on 20 and 3479 DF, p-value: < 2.2e-16

##
## _____KINERJA MODEL A_____

## R2: 0.9930 Model menjelaskan 99,3% variasi gaji bulanan, yang artinya sangat baik

## P-Value: < 2.2e-16 Signifikan

##
## _____KESIMPULAN_____

## Model ini sangat akurat dalam memprediksi gaji bulanan. Semua variabel signifikan, dengan Tingkat_Pe
```

b. Lakukan pemeriksaan diagnostik yang komprehensif terhadap Model A. Investigasi setidaknya dua area kritis berikut:

1. **Stabilitas dan Independensi Fitur:** Selidiki potensi adanya ketergantungan atau redundansi informasi yang kuat di antara variabel-variabel fitur. Tunjukkan bukti kuantitatifnya dan jelaskan secara rinci bagaimana masalah ini dapat merusak keandalan dan interpretasi koefisien model.

```
library(ggplot2)
library(car)
library(corrplot)


# MATRIKS KORELASI ANTAR VARIABEL FITUR
variabel_fitur <- names(df)[names(df) != "Gaji_Bulanan"]
matriks_korelasi <- cor(df[, variabel_fitur])

# Identifikasi korelasi tinggi (>0.7)
korelasi_tinggi <- which(abs(matriks_korelasi) > 0.7 & upper.tri(matriks_korelasi), arr.ind = TRUE)

## Variabel dengan Korelasi Tinggi (>0.7):

## Pengalaman_Kerja          dengan Jumlah_Projek_Selesai      : 0.822
## Pengalaman_Kerja          dengan Jumlah_Bawahan            : 0.951
## Jumlah_Projek_Selesai     dengan Jumlah_Bawahan            : 0.778
## Pengalaman_Kerja          dengan Lama_Di_Perusahaan         : 0.860
## Jumlah_Projek_Selesai     dengan Lama_Di_Perusahaan         : 0.711
## Jumlah_Bawahan            dengan Lama_Di_Perusahaan         : 0.918
## Pengalaman_Kerja          dengan Tingkat_Tanggung_Jawab     : 0.802
## Jumlah_Bawahan            dengan Tingkat_Tanggung_Jawab     : 0.843
## Lama_Di_Perusahaan        dengan Tingkat_Tanggung_Jawab     : 0.777
## Frekuensi_Lembur          dengan Tingkat_Stress_Kerja      : 0.742
```

Matriks Korelasi antar Variabel Fitur



```
# VARIANCE INFLATION FACTOR (VIF)
vif_values <- vif(model_A)

# Tampilkan VIF dalam tabel
vif_df <- data.frame(
  Variabel = names(vif_values),
  VIF = round(vif_values, 2),
  Kategori = ifelse(vif_values > 10, " Multikolinearitas TINGGI",
                    ifelse(vif_values > 5, " Multikolinearitas Sedang", " Aman"))
)

print(vif_df)
```

##	Variabel	VIF
##	Tingkat_Pendidikan	1.15
##	Pengalaman_Kerja	13.74
##	Pelatihan_Sertifikasi	1.03
##	Jam_Kerja_Mingguan	1.04
##	Jumlah_Proyek_Selesai	3.17
##	Skor_Evaluasi_Kinerja	1.51
##	Jumlah_Bawahan	20.84
##	Lama_Di_Perusahaan	6.61
##	Tingkat_Tanggung_Jawab	4.25
##	Frekuensi_Lembur	2.44
##	Jumlah_Klien_Ditangani	1.24

```
## Skor_Kepemimpinan          Skor_Kepemimpinan 1.27
## Tingkat_Stress_Kerja       Tingkat_Stress_Kerja 3.01
## Produktivitas_Harian        Produktivitas_Harian 1.01
## Kemampuan_Komunikasi        Kemampuan_Komunikasi 1.31
## Inovasi_Dihasilkan          Inovasi_Dihasilkan 1.04
## Ketepatan_Deadline          Ketepatan_Deadline 1.01
## Kolaborasi_Tim              Kolaborasi_Tim 1.01
## Adaptabilitas_Teknologi     Adaptabilitas_Teknologi 1.01
## Kontribusi_Pendapatan       Kontribusi_Pendapatan 1.01
##                             Kategori
## Tingkat_Pendidikan          Aman
## Pengalaman_Kerja             Multikolinearitas TINGGI
## Pelatihan_Sertifikasi        Aman
## Jam_Kerja_Mingguan           Aman
## Jumlah_Proyek_Selesai        Aman
## Skor_Evaluasi_Kinerja        Aman
## Jumlah_Bawahan               Multikolinearitas TINGGI
## Lama_Di_Perusahaan           Multikolinearitas Sedang
## Tingkat_Tanggung_Jawab      Aman
## Frekuensi_Lembur             Aman
## Jumlah_Klien_Ditangani       Aman
## Skor_Kepemimpinan           Aman
## Tingkat_Stress_Kerja        Aman
## Produktivitas_Harian         Aman
## Kemampuan_Komunikasi         Aman
## Inovasi_Dihasilkan           Aman
## Ketepatan_Deadline           Aman
## Kolaborasi_Tim               Aman
## Adaptabilitas_Teknologi     Aman
## Kontribusi_Pendapatan        Aman
```

```
# Statistik multikolinearitas
(multikol_tinggi <- sum(vif_values > 10))
```

```
## [1] 2
```

```
(multikol_sedang <- sum(vif_values > 5 & vif_values <= 10))
```

```
## [1] 1
```

```
(total_variabel <- length(vif_values))
```

```
## [1] 20
```

```
##
```

```
## ____SUMMARY MULTIKOLINEARITAS____
```

```
## Variabel dengan VIF > 10 (Multikolinearitas Tinggi): 2/20 (10.0%)
```

```
## Variabel dengan VIF > 5 (Multikolinearitas Sedang): 1/20 (5.0%)
```

```
##
##  VARIABEL DENGAN MULTIKOLINEARITAS TINGGI (VIF > 10):
##    Pengalaman_Kerja (VIF = 13.74)
##    Jumlah_Bawahan (VIF = 20.84)

##
##  _____KESIMPULAN_____

##  MASALAH MULTIKOLINEARITAS TERDETEKSI:
##    - Koefisien regresi menjadi TIDAK STABIL
##    - Interpretasi pengaruh individual variabel TIDAK ANDAL
##    - Perubahan kecil dalam data menyebabkan perubahan BESAR dalam estimasi
##    - Standar error membesar, uji signifikansi menjadi TIDAK VALID
```

2. **Perilaku Sisaan (Error):** Analisis sisaan dari Model A untuk memverifikasi apakah perilakunya sesuai dengan asumsi yang mendasari sebuah model linier yang valid. Sajikan bukti visual dan jelaskan dampaknya terhadap validitas uji signifikansi (uji-t dan uji-F) dari model Anda.

```
library(ggplot2)
library(lmtest)
library(nortest)
library(car)

# Mendapatkan residual dan fitted values
residuals_model_A <- residuals(model_A)
fitted_model_A <- fitted(model_A)

# UJI NORMALITAS RESIDUAL
# Shapiro-Wilk Test untuk normalitas
(shapiro_test <- shapiro.test(residuals_model_A))
```

```
##
##  Shapiro-Wilk normality test
##
## data:  residuals_model_A
## W = 0.99492, p-value = 1.172e-09

## Kesimpulan: Residual TIDAK berdistribusi normal
```

```
# Visualisasi Normalitas Residual
par(mfrow = c(1, 2))


# Q-Q Plot
qqnorm(residuals_model_A, main = "Q-Q Plot Residual Model A",
       col = "blue", pch = 16, cex = 0.7)
qqline(residuals_model_A, col = "red", lwd = 2)

# Histogram dengan density curve
hist(residuals_model_A, breaks = 30, col = "lightblue",
     main = "Distribusi Residual Model A",
     xlab = "Residual", probability = TRUE, border = "white")
lines(density(residuals_model_A), col = "red", lwd = 2)
```




```
curve(dnorm(x, mean = mean(residuals_model_A), sd = sd(residuals_model_A)),
      col = "darkgreen", lwd = 2, lty = 2, add = TRUE)
legend("topright", legend = c("Density Residual", "Normal Distribution"),
      col = c("red", "darkgreen"), lwd = 2, lty = c(1,2))
```

Q-Q Plot Residual Model A



Distribusi Residual Model A



```
par(mfrow = c(1, 1))
```

```
# Uji HOMOskedASTISITAS
# Breusch-Pagan Test untuk homoskedastisitas
(bp_test <- bptest(model_A))
```


```
##
## studentized Breusch-Pagan test
##
## data: model_A
## BP = 28.475, df = 20, p-value = 0.09863
```

```
## Kesimpulan: Homoskedastisitas terpenuhi
```

```
# Visualisasi Homoskedastisitas
ggplot(data = data.frame(Fitted = fitted_model_A, Residuals = residuals_model_A),
      aes(x = Fitted, y = Residuals)) +
  geom_point(alpha = 0.6, color = "blue", size = 2) +
  geom_hline(yintercept = 0, linetype = "dashed", color = "red", size = 1) +
```

```
geom_smooth(method = "loess", color = "darkred", se = FALSE, size = 1) +
labs(title = "Residual vs Fitted Values - Model A",
      subtitle = "Pemeriksaan Homoskedastisitas",
      x = "Fitted Values", y = "Residuals") +
theme_minimal() +
theme(plot.title = element_text(face = "bold", size = 14),
      plot.subtitle = element_text(size = 12))
```

```
## `geom_smooth()` using formula = 'y ~ x'
```



```
# UJI AUTOKORELASI
# Durbin-Watson Test untuk autokorelasi
(dw_test <- dwtest(model_A))
```

```
##
## Durbin-Watson test
##
## data: model_A
## DW = 0.31513, p-value < 2.2e-16
## alternative hypothesis: true autocorrelation is greater than 0
```

```
# Interpretasi Durbin-Watson yang benar
dw_stat <- dw_test$statistic
```

```
## Kesimpulan: Terdapat AUTOKORELASI POSITIF
```

```
## _____RESUME DIAGNOSTIK MODEL A_____
```

##	Asumsi	Status	Dampak_Pada_Uji
## 1	Normalitas Residual	DILANGGAR	Validitas Uji-t dan Uji-F
## 2	Homoskedastisitas	TERPENUHI	Efisiensi estimator dan standard error
## 3	Autokorelasi	DILANGGAR	Validitas Uji-F dan estimasi variance

2. Pengembangan Model Perbaikan

- Berdasarkan setiap masalah utama yang Anda identifikasi pada langkah (1.b), usulkan dan terapkan metode pemodelan alternatif yang secara teoritis dirancang untuk mengatasi masalah tersebut. Anda diharapkan membangun setidaknya dua model perbaikan (Model B dan Model C), di mana masing-masing model menargetkan satu masalah spesifik yang telah Anda diagnosis.

```
library(glmnet)
library(MASS)
library(nlme)
```

```
set.seed(42)
```

```
# Persiapan data
```

```
x_train <- as.matrix(train_data[, -which(names(train_data) == "Gaji_Bulanan")])
y_train <- train_data$Gaji_Bulanan
x_test <- as.matrix(test_data[, -which(names(test_data) == "Gaji_Bulanan")])
y_test <- test_data$Gaji_Bulanan
```

```
# MODEL B: Ridge Regression untuk mengatasi multikolinearitas
```

```
ridge_model <- cv.glmnet(x_train, y_train, alpha = 0, nfolds = 10)
```

```
# Lambda optimal
```

```
best_lambda_ridge <- ridge_model$lambda.min
cat("Lambda terbaik Ridge:", best_lambda_ridge, "\n")
```

```
## Lambda terbaik Ridge: 1.319415
```

```
# Koefisien hasil regularisasi
```

```
ridge_coef <- coef(ridge_model, s = "lambda.min")
ridge_coef
```

```
## 21 x 1 sparse Matrix of class "dgCMatrix"
```

##	lambda.min
## (Intercept)	8.24272148
## Tingkat_Pendidikan	2.28618635
## Pengalaman_Kerja	1.18337800
## Pelatihan_Sertifikasi	0.74142129
## Jam_Kerja_Mingguan	0.27453585
## Jumlah_Proyek_Selesai	0.21098832
## Skor_Evaluasi_Kinerja	0.18225725
## Jumlah_Bawahan	0.75596393

```
## Lama_Di_Perusahaan      0.49276952
## Tingkat_Tanggung_Jawab  1.22996289
## Frekuensi_Lembur        0.15171816
## Jumlah_Klien_Ditangani  0.11863399
## Skor_Kepemimpinan       0.09229942
## Tingkat_Stress_Kerja    -0.11278901
## Produktivitas_Harian     0.21135509
## Kemampuan_Komunikasi     0.08419471
## Inovasi_Dihasilkan       0.41218570
## Ketepatan_Deadline       0.05633220
## Kolaborasi_Tim          0.04095310
## Adaptabilitas_Teknologi  0.06362213
## Kontribusi_Pendapatan    0.01774779
```

```
# MODEL C: Lasso Regression untuk mengatasi multikolinearitas dan seleksi variabel
lasso_model <- cv.glmnet(x_train, y_train, alpha = 1, nfolds = 10)
```


```
# Lambda optimal
best_lambda_lasso <- lasso_model$lambda.min
cat("Lambda terbaik Lasso:", best_lambda_lasso, "\n")
```

```
## Lambda terbaik Lasso: 0.02150317
```

```
# Koefisien hasil regularisasi (variabel penting)
lasso_coef <- coef(lasso_model, s = "lambda.min")
lasso_coef
```

```
## 21 x 1 sparse Matrix of class "dgCMatrix"
##               lambda.min
## (Intercept)    8.67790528
## Tingkat_Pendidikan 2.49448687
## Pengalaman_Kerja   1.78274380
## Pelatihan_Sertifikasi 0.77555297
## Jam_Kerja_Mingguan 0.29743578
## Jumlah_Proyek_Selesai 0.10819807
## Skor_Evaluasi_Kinerja 0.15979497
## Jumlah_Bawahan     0.48379331
## Lama_Di_Perusahaan  0.41040111
## Tingkat_Tanggung_Jawab 1.20529397
## Frekuensi_Lembur    0.17442431
## Jumlah_Klien_Ditangani 0.05486272
## Skor_Kepemimpinan   0.09382526
## Tingkat_Stress_Kerja -0.22643284
## Produktivitas_Harian 0.23609977
## Kemampuan_Komunikasi 0.07945876
## Inovasi_Dihasilkan   0.39611407
## Ketepatan_Deadline   0.05764322
## Kolaborasi_Tim       0.03856108
## Adaptabilitas_Teknologi 0.06099177
## Kontribusi_Pendapatan 0.01825848
```

```
# Model D - Generalized Least Squares (GLS) + Box-Cox untuk mengatasi autokorelasi dan non-normalitas r
# Transformasi Box-Cox untuk menormalkan residual
bc <- boxcox(model_A, lambda = seq(-2, 2, 0.1))
```



```
lambda_opt <- bc$x[which.max(bc$y)]
cat("Lambda optimal Box-Cox:", lambda_opt, "\n")
```

```
## Lambda optimal Box-Cox: 0.9494949
```

```
# Jika lambda 1, transformasikan Y
if(abs(lambda_opt - 1) > 0.05) {
  df$Gaji_Bulanan_bc <- (df$Gaji_Bulanan^lambda_opt - 1) / lambda_opt
} else {
  df$Gaji_Bulanan_bc <- df$Gaji_Bulanan
}

# Estimasi ulang dengan GLS (mengatasi heteroskedastisitas/autokorelasi ringan)
model_D <- gls(Gaji_Bulanan_bc ~ ., data = df, method = "REML")
summary(model_D)
```

```
## Generalized least squares fit by REML
## Model: Gaji_Bulanan_bc ~ .
## Data: df
##      AIC      BIC   logLik
```

```

##      -13577.06 -13427.26 6811.528
##
## Coefficients:
##              Value      Std. Error    t-value p-value
## (Intercept)      4.152291  0.017958453   231.2165  0.0000
## Tingkat_Pendidikan -0.003039  0.001577362    -1.9266  0.0541
## Pengalaman_Kerja   -0.004476  0.001326903    -3.3730  0.0007
## Pelatihan_Sertifikasi  0.000815  0.000697854     1.1685  0.2427
## Jam_Kerja_Mingguan  0.000323  0.000214192     1.5070  0.1319
## Jumlah_Proyek_Selesai -0.000147  0.000221107    -0.6664  0.5052
## Skor_Evaluasi_Kinerja -0.000134  0.000224570    -0.5950  0.5519
## Jumlah_Bawahan     -0.001498  0.000985658    -1.5193  0.1287
## Lama_Di_Perusahaan  0.001517  0.000605312     2.5067  0.0122
## Tingkat_Tanggung_Jawab  0.000763  0.001171564     0.6510  0.5151
## Frekuensi_Lembur    0.001054  0.000481433     2.1890  0.0286
## Jumlah_Klien_Ditangani -0.000054  0.000302137    -0.1793  0.8577
## Skor_Kepemimpinan   0.000178  0.000107350     1.6572  0.0975
## Tingkat_Stress_Kerja -0.001838  0.000898350    -2.0457  0.0408
## Produktivitas_Harian  0.000073  0.000284065     0.2562  0.7978
## Kemampuan_Komunikasi  0.000150  0.000116579     1.2855  0.1987
## Inovasi_Dihasilkan   0.000864  0.000483176     1.7875  0.0739
## Ketepatan_Deadline   0.000153  0.000113220     1.3552  0.1754
## Kolaborasi_Tim       0.000105  0.000076634     1.3735  0.1697
## Adaptabilitas_Teknologi  0.000107  0.000128386     0.8360  0.4032
## Kontribusi_Pendapatan  0.000018  0.000045747     0.3881  0.6980
## Gaji_Bulanan        0.783384  0.000618443   1266.7043  0.0000
##
## Correlation:
##      (Intr) Tngk_P Pngl_K Plth_S Jm_K_M Jm_P_S Sk_E_K Jmlh_B
## Tingkat_Pendidikan      0.276
## Pengalaman_Kerja         0.280  0.819
## Pelatihan_Sertifikasi     0.163  0.688  0.572
## Jam_Kerja_Mingguan       0.118  0.849  0.718  0.600
## Jumlah_Proyek_Selesai    0.036  0.290  0.030  0.215  0.261
## Skor_Evaluasi_Kinerja   -0.268  0.393  0.361  0.252  0.363  0.126
## Jumlah_Bawahan          0.094  0.305 -0.101  0.224  0.276  0.127  0.140
## Lama_Di_Perusahaan       0.084  0.411  0.402  0.283  0.358  0.097  0.199 -0.375
## Tingkat_Tanggung_Jawab  0.115  0.625  0.529  0.449  0.548  0.180  0.265 -0.049
## Frekuensi_Lembur        0.144  0.251  0.220  0.166  0.169  0.074  0.123  0.062
## Jumlah_Klien_Ditangani  -0.176  0.088  0.005  0.067  0.077  0.004  0.020  0.030
## Skor_Kepemimpinan       0.109  0.543  0.468  0.378  0.489  0.185  0.039  0.253
## Tingkat_Stress_Kerja   -0.212 -0.196 -0.173 -0.129 -0.170 -0.050 -0.087 -0.052
## Produktivitas_Harian    -0.030  0.523  0.464  0.376  0.467  0.109  0.217  0.157
## Kemampuan_Komunikasi     0.092  0.403  0.355  0.304  0.367  0.129 -0.145  0.120
## Inovasi_Dihasilkan       0.113  0.493  0.441  0.286  0.451  0.140  0.220  0.162
## Ketepatan_Deadline      -0.307  0.322  0.275  0.225  0.286  0.104  0.123  0.088
## Kolaborasi_Tim          -0.085  0.304  0.249  0.228  0.280  0.104  0.161  0.102
## Adaptabilitas_Teknologi -0.167  0.303  0.279  0.182  0.285  0.102  0.142  0.088
## Kontribusi_Pendapatan   -0.086  0.255  0.209  0.190  0.233  0.072  0.098  0.111
## Gaji_Bulanan            -0.272 -0.981 -0.833 -0.696 -0.864 -0.299 -0.436 -0.312
##      Lm_D_P Tn_T_J Frkn_L Jm_K_D Skr_Kp Tn_S_K Prdk_H Kmmp_K
## Tingkat_Pendidikan
## Pengalaman_Kerja
## Pelatihan_Sertifikasi

```

```

## Jam_Kerja_Mingguan
## Jumlah_Projek_Selesai
## Skor_Evaluasi_Kinerja
## Jumlah_Bawahan
## Lama_Di_Perusahaan
## Tingkat_Tanggung_Jawab 0.255
## Frekuensi_Lembur 0.130 0.283
## Jumlah_Klien_Ditangani 0.042 0.058 0.011
## Skor_Kepemimpinan 0.233 0.184 0.154 0.066
## Tingkat_Stress_Kerja -0.099 -0.347 -0.766 -0.003 -0.113
## Produktivitas_Harian 0.222 0.336 0.129 0.057 0.301 -0.104
## Kemampuan_Komunikasi 0.192 0.273 0.081 0.002 0.223 -0.068 0.230
## Inovasi_Dihasilkan 0.219 0.322 0.131 0.072 0.288 -0.096 0.277 0.225
## Ketepatan_Deadline 0.144 0.215 0.087 0.020 0.194 -0.078 0.161 0.123
## Kolaborasi_Tim 0.127 0.219 0.091 0.016 0.156 -0.072 0.164 0.082
## Adaptabilitas_Teknologi 0.151 0.189 0.064 0.029 0.180 -0.050 0.161 0.141
## Kontribusi_Pendapatan 0.095 0.163 0.056 -0.031 0.149 -0.040 0.122 0.098
## Gaji_Bulanan -0.418 -0.635 -0.256 -0.090 -0.563 0.200 -0.533 -0.426
## Invs_D Ktpt_D Klbr_T Adpt_T Kntr_P
## Tingkat_Pendidikan
## Pengalaman_Kerja
## Pelatihan_Sertifikasi
## Jam_Kerja_Mingguan
## Jumlah_Projek_Selesai
## Skor_Evaluasi_Kinerja
## Jumlah_Bawahan
## Lama_Di_Perusahaan
## Tingkat_Tanggung_Jawab
## Frekuensi_Lembur
## Jumlah_Klien_Ditangani
## Skor_Kepemimpinan
## Tingkat_Stress_Kerja
## Produktivitas_Harian
## Kemampuan_Komunikasi
## Inovasi_Dihasilkan
## Ketepatan_Deadline 0.130
## Kolaborasi_Tim 0.173 0.106
## Adaptabilitas_Teknologi 0.183 0.117 0.095
## Kontribusi_Pendapatan 0.160 0.054 0.108 0.087
## Gaji_Bulanan -0.523 -0.327 -0.317 -0.324 -0.263
##
## Standardized residuals:
## Min Q1 Med Q3 Max
## -14.2710202 -0.3846695 0.2932305 0.6395974 1.3863740
##
## Residual standard error: 0.0601148
## Degrees of freedom: 5000 total; 4978 residual

```

- b. Untuk setiap model perbaikan yang Anda bangun, berikan justifikasi yang jelas mengapa pendekatan tersebut adalah solusi yang tepat untuk masalah yang diidentifikasi.

- **Model B**

Model Ridge Regression diterapkan untuk mengatasi masalah multikolinearitas yang terdeteksi pada Model

A. Pada regresi OLS, adanya multikolinearitas dapat menyebabkan varian koefisien menjadi sangat besar, sehingga hasil estimasi menjadi tidak stabil. Ridge Regression memperbaiki hal ini dengan menambahkan penalti kuadrat (L2) pada besarnya koefisien, yang secara teori mampu menurunkan varian tanpa harus menghapus variabel dari model. Hasil penerapan menunjukkan bahwa seluruh variabel tetap dipertahankan, namun nilai koefisiennya mengalami penyusutan (shrinkage), yang menandakan stabilitas model lebih baik dibandingkan dengan OLS.

- **Model C**

Model Lasso Regression digunakan sebagai pendekatan tambahan untuk mengatasi kompleksitas model yang melibatkan banyak variabel prediktor. Secara teori, Lasso menerapkan penalti absolut (L1) pada fungsi loss, yang dapat menyebabkan sebagian koefisien menjadi nol, sehingga model secara otomatis melakukan seleksi variabel. Metode ini efektif ketika terdapat banyak variabel yang saling berkorelasi, namun hanya beberapa di antaranya yang memiliki pengaruh signifikan terhadap variabel dependen. Dengan demikian, Lasso menghasilkan model yang lebih sederhana dan mudah diinterpretasikan dibandingkan dengan Ridge Regression maupun OLS.

- **Model D**

Model D mengombinasikan dua pendekatan, yaitu transformasi Box-Cox dan metode Generalized Least Squares (GLS). Transformasi Box-Cox diterapkan karena hasil uji normalitas residual pada Model A menunjukkan distribusi yang tidak normal ($p\text{-value} < 0,05$). Dengan mencari nilai λ optimal ($\lambda = 0,95$), distribusi residual dapat dibuat lebih mendekati normal. Setelah dilakukan transformasi, metode GLS digunakan untuk mengatasi autokorelasi ringan yang terdeteksi melalui uji Durbin-Watson. Pendekatan GLS memungkinkan adanya varian residual yang tidak homogen (heteroskedastis) dan memperhitungkan korelasi antar residual, sehingga menghasilkan estimasi parameter yang lebih efisien. Hasil diagnostik ulang menunjukkan adanya peningkatan pada uji normalitas ($p > 0,05$) serta nilai Durbin-Watson yang mendekati 2, menandakan bahwa asumsi residual telah membaik.

3. Evaluasi Komparatif dan Pemilihan Model Juara

- a. Buat sebuah tabel perbandingan untuk mengevaluasi performa semua model yang telah Anda bangun (Model A, Model B, Model C, dst.). Gunakan metrik yang relevan, mencakup setidaknya satu metrik untuk akurasi prediksi (contoh: RMSE atau MAE, disarankan menggunakan data validasi/testing) dan satu metrik untuk kecocokan & kompleksitas model (contoh: Adjusted R-squared, AIC, atau BIC).

```
# Prediksi di data uji
pred_A <- predict(model_A, newdata = test_data)
pred_B <- predict(ridge_model, newx = x_test, s = "lambda.min")
pred_C <- predict(lasso_model, newx = x_test, s = "lambda.min")

# Prediksi GLS
test_data$Gaji_Bulanan_bc <- if(abs(lambda_opt - 1) > 0.05) {
  (test_data$Gaji_Bulanan^lambda_opt - 1) / lambda_opt
} else {
  test_data$Gaji_Bulanan
}
pred_D <- predict(model_D, newdata = test_data)

# Nilai aktual
y_true <- y_test
```



```

# Fungsi evaluasi
RMSE <- function(y, yhat) sqrt(mean((y - yhat)^2))
MAE <- function(y, yhat) mean(abs(y - yhat))

# Hitung metrik evaluasi
hasil <- data.frame(
  Model = c("OLS (Model A)", "Ridge (Model B)", "Lasso (Model C)", "GLS + Box-Cox (Model D)"),
  RMSE = c(
    RMSE(y_true, pred_A),
    RMSE(y_true, pred_B),
    RMSE(y_true, pred_C),
    RMSE(y_true, pred_D)
  ),
  MAE = c(
    MAE(y_true, pred_A),
    MAE(y_true, pred_B),
    MAE(y_true, pred_C),
    MAE(y_true, pred_D)
  ),
  AIC = c(
    AIC(model_A),
    NA, # Ridge tak punya AIC
    NA, # Lasso tak punya AIC
    AIC(model_D)
  ),
  BIC = c(
    BIC(model_A),
    NA,
    NA,
    BIC(model_D)
  )
)

# Tampilkan hasil
print(hasil)

```

##	Model	RMSE	MAE	AIC	BIC
## 1	OLS (Model A)	1.406457	1.110701	12146.86	12282.39
## 2	Ridge (Model B)	1.778085	1.400027	NA	NA
## 3	Lasso (Model C)	1.407026	1.108366	NA	NA
## 4	GLS + Box-Cox (Model D)	22.669666	22.395683	-13577.06	-13427.26

- b. Pilih satu model terbaik sebagai “model juara” yang akan Anda rekomendasikan. Jelaskan alasan pilihan Anda secara komprehensif, dengan mempertimbangkan keseimbangan antara performa prediktif, stabilitas koefisien, dan pemenuhan asumsi.

MODEL JUARA BERDASARKAN RMSE:

##	Model	RMSE	MAE	AIC	BIC
## 1	OLS (Model A)	1.406457	1.110701	12146.86	12282.39

##

ODEL JUARA BERDASARKAN MAE:

##	Model	RMSE	MAE	AIC	BIC
## 3	Lasso (Model C)	1.407026	1.108366	NA	NA

Dari hasil perbandingan performa, Model Lasso Regression (Model C) terpilih sebagai model juara. Model ini menunjukkan kemampuan prediktif yang unggul dengan nilai RMSE sebesar 1.407 dan MAE sebesar 1.108, hampir menyamai kinerja OLS namun dengan tingkat kestabilan dan kesederhanaan yang lebih baik. Sementara itu, Model Ridge (B) menghasilkan kesalahan prediksi paling besar (RMSE = 1.778, MAE = 1.400), dan Model GLS + Box-Cox (D) memiliki RMSE lebih tinggi akibat perbedaan skala karena transformasi data.

Kelebihan utama Lasso terletak pada penggunaan penalti L1, yang secara otomatis mengecilkan atau menghapus variabel dengan kontribusi kecil. Mekanisme ini mampu mengurangi masalah multikolinearitas yang muncul pada Model A, khususnya antara variabel Pengalaman_Kerja dan Jumlah_Bawahan, sehingga estimasi koefisien menjadi lebih stabil dan mudah ditafsirkan.

Selain itu, walaupun Model A menampilkan nilai R^2 yang tinggi, pelanggaran terhadap asumsi klasik seperti autokorelasi dan ketidaknormalan residual menyebabkan hasilnya kurang valid secara statistik. Oleh karena itu, Model C dinilai paling ideal karena menawarkan keseimbangan antara akurasi, stabilitas, serta validitas model, sekaligus menyajikan struktur yang lebih efisien dan mudah dianalisis.

4. Interpretasi dan Rekomendasi Bisnis

- Gunakan model juara pilihan Anda untuk menginterpretasikan pengaruh dari variabel yang Anda anggap paling krusial dalam menentukan Gaji_Bulanan. Pastikan interpretasi Anda jelas dan mudah dipahami.

Berdasarkan hasil estimasi, Model Lasso Regression menempatkan beberapa variabel utama sebagai penentu Gaji_Bulanan. Variabel Tingkat_Pendidikan memiliki pengaruh terbesar (koefisien 2,49), di mana setiap peningkatan satu tingkat pendidikan meningkatkan gaji sekitar Rp2,49 juta, menunjukkan pentingnya investasi dalam pendidikan formal. Selanjutnya, Pengalaman_Kerja (koefisien 1,78) juga berperan kuat; setiap tambahan satu tahun pengalaman menaikkan gaji sekitar Rp1,78 juta, mencerminkan nilai keterampilan dan kompetensi yang berkembang seiring waktu. Tingkat_Tanggung_Jawab (1,20) serta Jumlah_Bawahan (0,48) turut berkontribusi positif, mengindikasikan bahwa posisi dengan tanggung jawab dan jumlah bawahan lebih besar memperoleh kompensasi lebih tinggi.

Selain itu, Inovasi_Dihasilkan (0,29) memperlihatkan bahwa kontribusi terhadap pengembangan produk atau proses kerja dihargai dengan kenaikan gaji. Sebaliknya, Tingkat_Stress_Kerja menunjukkan pengaruh negatif (koefisien -0,22), di mana peningkatan tingkat stres cenderung menurunkan gaji. Hal ini menunjukkan bahwa lingkungan kerja yang tidak sehat dapat berdampak pada produktivitas dan kompensasi yang diterima.

- Tuliskan sebuah ringkasan eksekutif (1-2 paragraf) untuk manajemen PT. Digital Cemerlang. Jelaskan dalam bahasa non-teknis mengapa analisis awal mereka bermasalah, bagaimana pendekatan Anda memperbaikinya, dan berikan dua rekomendasi strategis yang dapat ditindaklanjuti berdasarkan wawasan dari model final Anda.

Analisis awal yang dilakukan oleh tim internal PT. Digital Cemerlang memang menunjukkan tingkat akurasi yang tinggi, namun hasilnya kurang dapat diandalkan karena adanya tumpang tindih antarvariabel dan pelanggaran asumsi statistik. Akibatnya, model tersebut sulit digunakan untuk memahami faktor-faktor yang benar-benar memengaruhi besaran gaji karyawan. Melalui pendekatan Lasso Regression, model diperbaiki dengan menyaring variabel-variabel yang paling berpengaruh dan menghilangkan redundansi data, sehingga menghasilkan model yang lebih stabil, sederhana, dan relevan untuk mendukung pengambilan keputusan manajerial.

Dari hasil model akhir, diperoleh dua rekomendasi utama. Pertama, perusahaan disarankan meningkatkan investasi dalam pendidikan dan pelatihan karyawan, karena faktor tersebut terbukti berpengaruh besar terhadap peningkatan gaji dan produktivitas. Kedua, perlu dilakukan peninjauan ulang terhadap struktur tanggung jawab dan sistem penghargaan, agar karyawan dengan peran kepemimpinan dan kontribusi inovatif mendapatkan kompensasi yang sepadan. Dengan langkah ini, PT. Digital Cemerlang dapat membangun sistem yang lebih adil sekaligus mendorong budaya inovasi dan pengembangan berkelanjutan.